

# 联邦学习

2023 年 8 月 3 日

## 1 收敛性

定义相似度矩阵  $\mathbf{L} \in \mathbb{R}^{N \times N}$ ,  $\mathbf{L}_{i,j}$  表示 client  $i$  和 client  $j$  的相似度, k-DPP 采样: 给出子集  $\mathbf{Y}$  的采样概率, 其中  $\mathbf{Y}$  表示  $k$  个 clients 的集合。

$$\mathbf{P}(\mathbf{Y}) = \frac{\det(\mathbf{L}_{\mathbf{Y}})}{\sum_{|\mathbf{Y}'|=k} \det(\mathbf{L}_{\mathbf{Y}'})} \quad (1)$$

目标函数

$$\mathbf{J}(\theta) = \mathbb{E}_{x \sim p_{data}} [l(x; \theta)] \quad (2)$$

其中  $p_{data}$  是真实分布。

联邦学习的优化目标

$$\mathbf{F}(\theta) = \sum_{i=1}^n p_i f_i(\theta) = \sum_{i=1}^n \frac{D_i}{\sum_{i=1}^n D_i} \frac{1}{D_i} \sum_{x \in \mathcal{D}_i} l(x; \theta) \quad (3)$$

定义  $m_i$  表示在 dpp 采样时 client  $i$  是否被选中,  $m_i \in \{0, 1\}$ ,  $b_i = \mathbb{E}(m_i)$ , 当使用 dpp 采样方法时, 重新定义优化目标为:

$$\hat{\mathbf{F}}(\theta) = \frac{1}{k} \sum_{i=1}^n b_i f_i(\theta) = \frac{1}{k} \sum_{i=1}^n b_i \frac{1}{D_i} \sum_{x \in \mathcal{D}_i} l(x; \theta) \quad (4)$$

更新策略:

$$\theta = \theta - \frac{1}{k} \sum_{i=1}^n m_i \nabla \hat{f}_i(\theta) \quad (5)$$

其中  $\nabla \hat{f}_i(\theta) = \sum_{t=1}^T \frac{1}{|\mathcal{B}_{i,t}|} \sum_{x \in \mathcal{B}_{i,t}} \nabla l(x; \theta_t)$

根据更新策略, 求参数更新值的期望:

$$\mathbb{E}(g) = \mathbb{E}\left(\frac{1}{k} \sum_{i=1}^n m_i \nabla \hat{f}_i(\theta)\right) = \frac{1}{k} \sum_{i=1}^n b_i \nabla \hat{f}_i(\theta) \quad (6)$$

这个期望和目标函数  $\hat{F}(\theta)$  的更新值相等, 所以是策略是无偏的。

定义协方差

$$\mathbf{C}_{i,j} = \frac{\mathbb{E}[(m_i - b_i)(m_j - b_j)]}{\mathbb{E}(m_i)\mathbb{E}(m_j)} = \frac{\mathbb{E}(m_i m_j)}{b_i b_j} - 1 \quad (7)$$

计算参数更新值的方差:

$$Var(g) = \mathbb{E}[(g - \mathbb{E}(g))^2] = \mathbb{E}\left[\left(\frac{1}{k} \sum_{i=1}^n m_i \nabla \hat{f}_i(\theta) - \frac{1}{k} \sum_{i=1}^n b_i \nabla \hat{f}_i(\theta)\right)^2\right] = \frac{1}{k^2} \mathbb{E}\left[\left(\sum_{i=1}^n (m_i - b_i) \nabla \hat{f}_i(\theta)\right)^2\right] \quad (8)$$

$$= \frac{1}{k^2} \mathbb{E}[(\sum_{i,j=1}^n (m_i - b_i)(m_j - b_j) \nabla \hat{f}_i^T(\theta) \nabla \hat{f}_j(\theta))] = \frac{1}{k^2} (\sum_{i,j=1}^n \mathbb{E}[(m_i - b_i)(m_j - b_j)] \nabla \hat{f}_i^T(\theta) \nabla \hat{f}_j(\theta)) \quad (9)$$

$$\begin{aligned} \mathbb{E}[m_i m_j] &= \mathbb{E}[m_i^2] \sigma_{ij} + \mathbb{E}[m_i m_j] (1 - \sigma_{ij}) \\ &= \mathbb{E}[m_i] \sigma_{ij} + (\mathbf{C}_{ij} + 1) b_i b_j (1 - \sigma_{ij}) \end{aligned} \quad (10)$$

其中  $\sigma_{ij} = \begin{cases} 1, i = j \\ 0, i \neq j \end{cases}$

$$\mathbb{E}[(m_i - b_i)(m_j - b_j)] = \mathbb{E}[m_j m_i] - b_i b_j \quad (11)$$

$$\begin{aligned} Var(g) &= \frac{1}{k^2} \sum_{i=1}^n (b_i - b_i^2) \|\nabla \hat{f}_i(\theta)\|^2 \\ &\quad + \frac{1}{k^2} \sum_{i \neq j} \mathbf{C}_{i,j} b_i b_j \nabla \hat{f}_i^T(\theta) \nabla \hat{f}_j(\theta) \end{aligned} \quad (12)$$

假设  $\mathbf{C}_{ij} \nabla \hat{f}_i^T(\theta) \nabla \hat{f}_j(\theta) < 0$  , 因此  $Var(g)$  减小了。